
Business Intelligence

Praktikum 3: Der ETL-Prozess mit Hilfe des graphischen Tools KNIME

Wintersemester 2025/2026

Prof. Dr. Arnim Malcherek

Prof. Dr. Susanne Hoffmeister

Inhaltlicher Rahmen:

Das fiktive Beispielszenario, das wir im Rahmen des Praktikums betrachten, stammt aus der Augenmedizin. Das Wort Business wird hier also im weiteren Sinn aufgefasst (vergleiche auch mit Original-Paper von H.P. Luhn).

Seit mehreren Jahren wird durch die deutsche ophthalmologische Gesellschaft ein deutsches Augenregister (in grober Analogie zum deutschen Krebsregister) geplant und umgesetzt ([Link zum tatsächlichen Register](#)). Das Universitätsklinikum Münster spielt hierbei eine Vorreiterrolle.

Soweit die Realität und jetzt der Übergang zur Fiktion: Um erste Erfahrungen mit den Schwierigkeiten, Möglichkeiten und der technischen Gestaltung eines Data Warehouses zu sammeln, werden Daten von Erstuntersuchungen des Jahres 2021 aus zwei Universitätskliniken und wenigen ausgewählten jeweils umliegenden Augenarztpraxen in einem einfachen csv-Format exportiert, und Sie als BI-Consultant bekommen den Auftrag, damit ein Mini-Data Warehouse aufzubauen, aus dem dann die Reporting Marts generiert werden sollen.

Da wir aus Datenschutzgründen nicht mit Echtdaten arbeiten können, sind die Daten künstlich erzeugt, reinktiv und an vielen Stellen deshalb medizinisch nicht widerspruchsfrei. Als eine von vielen Vereinfachungen wird auch nicht zwischen beiden Augen der Patienten unterschieden, sondern es wird angenommen, dass bei der Untersuchung nur jeweils ein Auge der Patienten betroffen ist.

Vorarbeiten: Installieren Sie sich KNIME, oder nutzen Sie alternativ den Horizon-Server.

Aufgabe 1

Auf Moodle finden Sie einen Satz von csv-Dateien für die zwei Unikliniken Münster und Saarland und Augenarztpraxen in den jeweils umliegenden Städten Coesfeld, Hamm, Telgte, Unna und Warendorf sowie Neunkirchen, Pirmasens, St. Wendel und Zweibrücken. Zu jeder Praxis/Klinik gibt es drei Dateien:

- Stammdaten der Patienten in *praxis_XYZ_stammdaten.csv*
- Verschiedene Messwerte und die jeweilige Diagnose des Patienten zusammen mit dem Untersuchungsdatum in *praxis_XYZ_messwerte.csv*
- Derzeit maximal zwei Anamnese-Codes in *praxis_XYZ_anamnesen.csv*

Anamnesen und Diagnosen verwenden das hierarchisch aufgebaute ICD-System (International Code of Disease). Die Bezeichnungen der Krankheiten und Informationen zum Aufbau des Systems finden Sie unter ICD10.

Zusätzlich finden Sie drei Dateien, die die Strukturdaten der verschiedenen Ebenen des ICD-Systems enthalten:

- ICD-Codes in *ICD_Codes.csv*
- ICD-Gruppen in *ICD_Gruppen.csv*
- ICD-Kapitel in *ICD_Kapitel.csv*

Diese Dateien stammen von der Seite des *Deutschen Instituts für Medizinische Dokumentation und Information*. Sie benötigen sie erst im weiteren Verlauf für die Reporting Marts.

- (a) Machen Sie sich mit der Struktur des ICD-Systems vertraut.
- (b) Verschaffen Sie sich einen Überblick über Form und Inhalt der Patientendaten.
- (c) Um die Daten der verschiedenen Arztpraxen und Kliniken dauerhaft abzuspeichern, entwerfen Sie mit Hilfe von MySQL-Model oder SAP Power Designer ein EER-Diagramm für einen Data Vault. Die Daten sollen im Data Warehouse mit einem einheitlichen Patientenschlüssel zusammengelegt und nicht mehr nach Herkunft getrennt werden (also nur eine Stammdatentabelle statt eine Tabelle pro Praxis usw.); Patientennummern der verschiedenen Praxen sind nicht eindeutig. Die Herkunft der Daten (also die jeweilige Praxis) ist als Attribut zu speichern. Berücksichtigen Sie in Ihrem Design schon, dass man später damit geographische Auswertungen machen können soll (Kreis, Bezirk, Bundesland etc.). All diese Attribute müssen Sie noch nicht anlegen, aber Ihre Tabellenstruktur sollte dafür leicht erweiterbar sein.
- (d) Verwenden Sie in Ihrem Design GUIDs als Tabellenschlüssel (**char(36)**), damit das System potentiell beliebig portierbar und zusammenlegbar mit anderen Registern ist.
- (e) Implementieren Sie das Modell mit Hilfe der MySQL-Workbench (Menü: *Database -> Forward engineer*) oder PostgreSQL in einem eigenen Datenbankschema.

Aufgabe 2

Lesen Sie die csv-Dateien mit Hilfe von KNIME ein, und befüllen Sie Ihr Data Warehouse. Gehen Sie dazu vor wie folgt:

- (a) Starten Sie KNIME entweder von Ihrem Rechner oder aus der Remote Desktop-Umgebung des Praktikums. Machen Sie sich mit Hilfe folgender Materialien mit KNIME vertraut:
 - Cheat-Sheet auf Moodle
 - Beispiel-Workflows in KNIME selbst
 - Getting-Started-Guide unter <https://www.knime.com/getting-started-guide>
 - Tutorial Videos Ihrer Wahl aus dem Netz
- (b) Legen Sie zunächst einen Workflow in KNIME an, mit dem Sie die csv-Dateien der Stammdaten einlesen. Fügen Sie die Daten der verschiedenen Praxen/Kliniken im Workflow zusammen, und befüllen Sie damit Ihre Stammdatentabelle(n) in MySQL oder PostgreSQL aus Aufgabe 1. Legen Sie die GUID z.B. mit Hilfe eines Java- oder Python-Snippets an.
- (c) Sie müssen keinen Delta-Upload vorsehen. Wenn die Daten neu eingelesen werden, löschen Sie vorher ihre Zieltabellen mit `truncate table`. Dazu können Sie den KNIME-Knoten **DB SQL Executor** nutzen.
- (d) Manche Patienten haben verschiedene Praxen/Kliniken besucht, um eine zweite Meinung einzuholen. Bei einigen kam es dabei zu unterschiedlichen Namensschreibweisen. Identifizieren Sie die Dubletten (ein Patient gilt als identisch, wenn sein Geburtsdatum identisch und sein Name und Vorname „ähnlich“ ist). Ähnlichkeit können Sie mit Hilfe des Levenshtein-Algorithmus überprüfen. Implementieren Sie den Levenshtein-Algorithmus entweder selbst als KNIME-Knoten vom Typ Java-Snippet oder als Python-Code, oder nutzen Sie die in KNIME eingebauten Möglichkeiten (einfacher Weg). Sie müssen Dubletten nicht automatisch beheben. Es genügt, wenn Sie sie identifizieren und kennzeichnen (z.B. über zusätzliches Attribut). Danach kann die entsprechende csv-Datei manuell angepasst und der Input erneut gestartet werden. Wenn Sie eine automatische Behebung zuverlässig hinbekommen, ist das natürlich auch schön.
- (e) Füllen Sie jetzt auch die übrigen Tabellen (Tensio-, Refraktionswerte und Visuswerte, Diagnosen, Anamnesen). Eventuell müssen Sie in den Input-Daten dabei noch Fehler bereinigen oder Formate ändern. Notieren Sie sich eventuelle Auffälligkeiten in den Daten (Ausreißer, unplausible Werte etc.).