

Business Intelligence

Praktikum 6

Wintersemester 2025/26

Prof. Dr. Susanne Hoffmeister, Prof. Dr. Arnim Malcherek

Lernziele

- Sie können Transaktionsdaten für Assoziationsregel-Mining vorbereiten
- Sie verstehen die Anwendung des Apriori-Algorithmus
- Sie können Assoziationsregeln interpretieren und bewerten
- Sie kennen die Bedeutung von Support, Confidence und Lift
- Sie können Regeln für geschäftliche Anwendungen filtern und auswerten

Inhaltlicher Rahmen

Dieses Praktikum verwendet den TPC-DS Benchmark-Datensatz, der bereits in Snowflake als Sample Data verfügbar ist. Sie lernen, wie man Assoziationsregeln aus Verkaufsdaten extrahiert und interpretiert. Der Fokus liegt auf der praktischen Anwendung des Apriori-Algorithmus mit der Python-Bibliothek `mlxtend`.

Hinweise:

- **Zugangsdaten:** Sie erhalten Ihre Zugangsdaten für Ihren persönlichen Snowflake Account zu Beginn des Praktikums vom Dozenten. Das temporäre Passwort müssen Sie bei ihrem ersten Login ändern. Danach haben nur noch Sie Zugriff auf Ihren Account.
- **Notebook:** Verwenden Sie ein Snowflake Notebook für diese Aufgabe. Erstellen Sie ein neues Notebook.
- **Bibliothek:** Die Bibliothek `mlxtend` ist bereits in Snowflake verfügbar und kann als Package im Notebook environment hinzugefügt werden.
- **TPC-DS Daten:** Der TPC-DS Datensatz ist bereits in Snowflake verfügbar unter `SNOWFLAKE_SAMPLE_DATA.TPCDS_SF10TCL`.

Aufgabe 1: Assoziationsregel-Mining mit TPC-DS Daten

In dieser Aufgabe lernen Sie, wie man Assoziationsregeln aus Verkaufsdaten extrahiert. Sie verwenden den TPC-DS Benchmark-Datensatz, der bereits in Snowflake verfügbar ist, und den Apriori-Algorithmus zur Identifikation von Produktkategorien, die häufig gemeinsam gekauft werden.

Teilaufgabe 1: Datenvorbereitung

- (1) Erstellen Sie ein neues Notebook in Snowflake. Als Notebook location soll `PRAKTIKUM6_DB` ausgewählt werden und als Schema das Schema ihrer Gruppe (z.B. `GROUP_01_SCHEMA`). Als Query warehouse können Sie `NOTEBOOK_WH` benutzen.
- (2) Importieren Sie die notwendigen Python-Bibliotheken:

```
import pandas as pd
from mlxtend.preprocessing import TransactionEncoder
from mlxtend.frequent_patterns import apriori, association_rules
```
- (3) Erstellen Sie eine SQL-Query, die die Transaktionsdaten aus TPC-DS extrahiert:
 - Verwenden Sie die Tabelle `STORE_SALES` aus dem Schema `SNOWFLAKE_SAMPLE_DATA.TPCDS_SF10TCL`
 - Joinen Sie mit der Tabelle `ITEM`, um die Produktkategorien zu erhalten
 - Selektieren Sie `ss_ticket_number` als `L_ORDERKEY` und `i_category` als `L_CATEGORY`
 - Filtern Sie nach `ss_quantity > 0` und `i_category IS NOT NULL`
 - Begrenzen Sie die Ergebnisse auf 100.000 Zeilen für die erste Analyse
- (4) Konvertieren Sie das SQL-Ergebnis zu einem Pandas DataFrame und transformieren Sie es in Transaktionsdaten:
 - Gruppieren Sie nach `L_ORDERKEY`
 - Sammeln Sie alle `L_CATEGORY`-Werte pro Order in einer Liste
 - Verwenden Sie `unique()`, um Duplikate zu entfernen
 - Konvertieren Sie zu einer Liste von Listen (Format für `mlxtend`)
- (5) Überprüfen Sie die Daten:
 - Wie viele Transaktionen haben Sie?
 - Wie viele eindeutige Kategorien gibt es?
 - Zeigen Sie die ersten 5 Transaktionen an

Teilaufgabe 2: One-Hot-Encoding und Apriori-Algorithmus

- (1) Konvertieren Sie die Transaktionsdaten mit `TransactionEncoder` in ein One-Hot-Encoding Format:
 - Erstellen Sie eine binäre Matrix, bei der jede Zeile eine Transaktion und jede Spalte eine Kategorie repräsentiert
 - Überprüfen Sie die Dimensionen der resultierenden Matrix

- (2) Wenden Sie den Apriori-Algorithmus an:
- Verwenden Sie **min_support** = 0.20 (20%)
 - Erklären Sie, warum wir mit Kategorien höhere Support-Werte verwenden können als mit einzelnen Produkten
 - Zeigen Sie die gefundenen häufigen Itemsets an, sortiert nach Support
 - Analysieren Sie die Verteilung nach Itemset-Größe (1-Itemsets, 2-Itemsets, etc.)

Teilaufgabe 3: Generierung und Analyse von Assoziationsregeln

- (1) Generieren Sie Assoziationsregeln aus den häufigen Itemsets:
- Verwenden Sie **min_confidence** = 0.1 (10%)
 - Sortieren Sie nach Confidence
- (2) Analysieren Sie die generierten Regeln:
- Wie viele Regeln wurden gefunden?
 - Berechnen Sie die Statistiken (Min, Max, Mean) für Support, Confidence und Lift
 - Identifizieren Sie die Top 10 Regeln nach Lift (stärkste Assoziationen)
 - Identifizieren Sie die Top 10 Regeln nach Confidence (zuverlässigste Regeln)
- (3) Interpretieren Sie die Ergebnisse:
- Welche Regeln haben einen Lift > 1.0 ? Was bedeutet das?
 - Welche Regeln haben sowohl Lift > 1.0 als auch Confidence > 0.5 ?
 - Formulieren Sie diese Regeln in natürlicher Sprache (z.B. "Wenn Kunden Kategorie X kaufen, dann kaufen sie auch Kategorie Y in Z% der Fälle")

Teilaufgabe 4: Interpretation und geschäftliche Anwendung

- (1) Erklären Sie die Bedeutung der folgenden Kennzahlen anhand Ihrer Ergebnisse:
- **Support:** Was bedeutet ein Support von 0.15 in Ihrem Kontext?
 - **Confidence:** Was bedeutet eine Confidence von 0.8?
 - **Lift:** Was bedeutet ein Lift von 2.5? Was bedeutet Lift = 1?
- (2) Filtern Sie die Regeln nach geschäftlichen Kriterien:
- Finden Sie alle Regeln mit **Lift** > 1.2 UND **Confidence** > 0.7
 - Wie viele solcher "starken und zuverlässigen" Regeln gibt es?
 - Welche dieser Regeln wären für Cross-Selling-Strategien am besten geeignet?
- (3) Diskutieren Sie die praktische Anwendbarkeit:
- Welche der gefundenen Regeln könnten für Produktplatzierung genutzt werden?
 - Welche Regeln könnten in ein Empfehlungssystem integriert werden?
 - Gibt es Regeln, die statistisch signifikant, aber geschäftlich nicht umsetzbar sind?